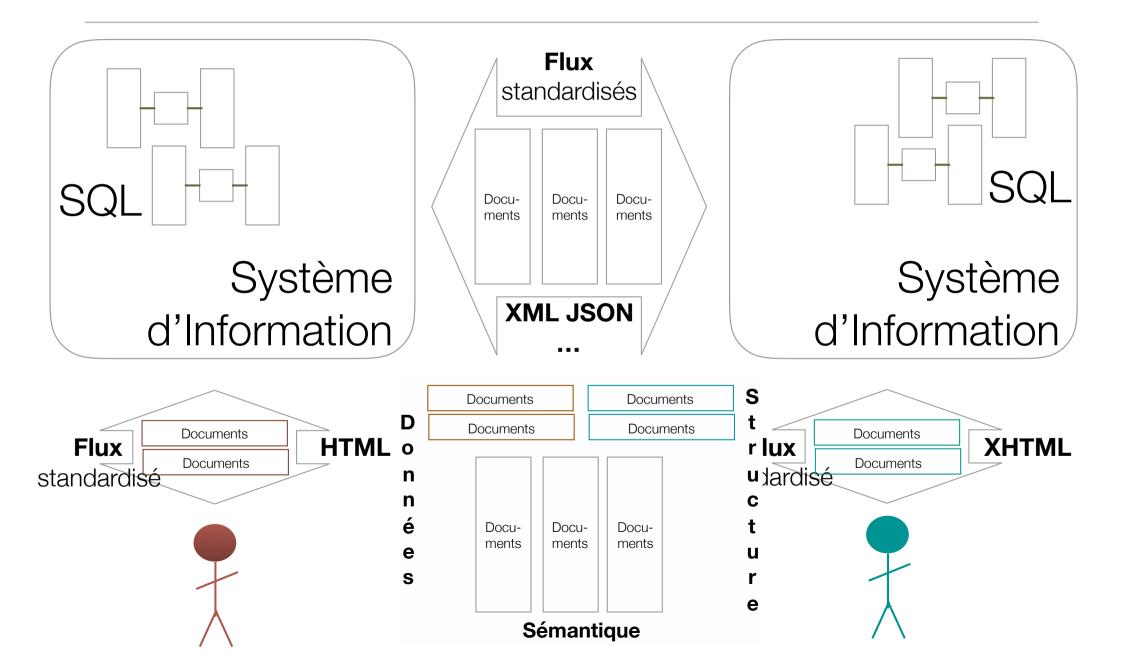
LABD

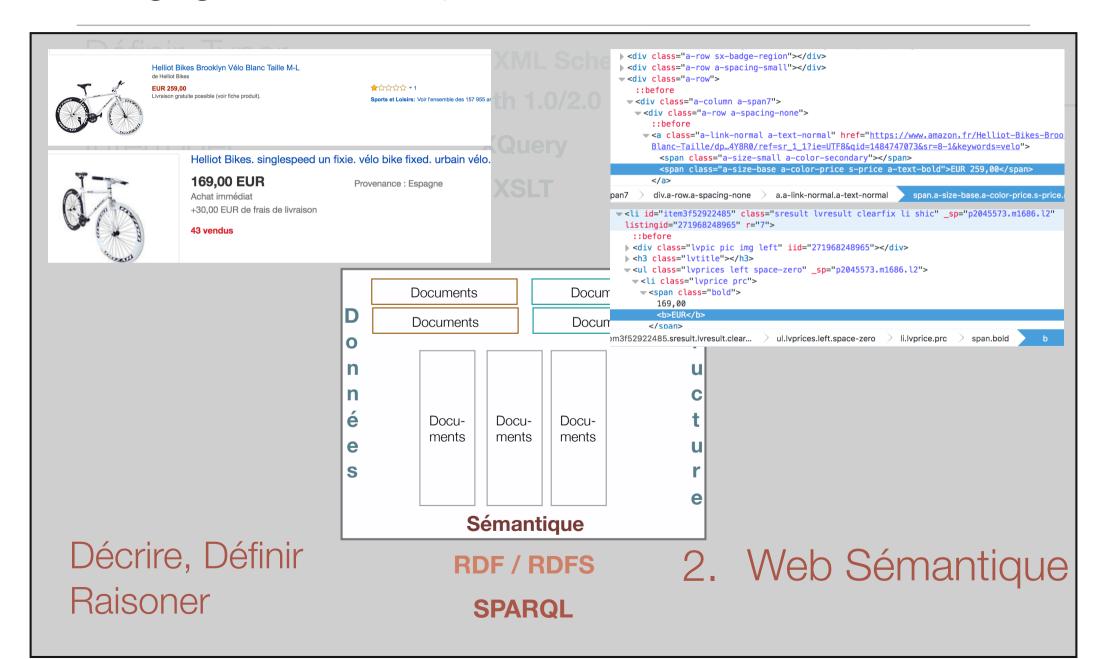
Master Info M1 2017-2018

LABD 8 : WEB Sémantique

Bases de données, Systèmes d'Informations et Documents



Langages Avancés pour les Bases de Données



WEB 1.0, les tout débuts

web = pages statiques liées entre-elles par des liens hypertexts.

Utilisateur = lecteur

mise à jours (relativement) rares

1990-1992 http, html

1992-1995 url, w3c, mosaic, netscape, ie, images, tables

WEB 1.0 maturité

Séparer forme et contenu (données/traitements/ présentation)

web = collection de documents structurés

1994 W3C

1996 feuilles de style

1998 XML, DTD

2000-2010 XML-Schema, XHTML, SVG, XPath, XLink, XPointer, Xslt, Xquery

WEB 2.0

Ensemble de ressources-documents de très grandes taille

web et web caché

Outils de recherches syntaxiques

Utilisateur = acteur : complexification interne vs simplicité de publication

Wikipedia - Myspace - réseaux sociaux

WEB 3.0 ?

Pas de définition officielle

Web des données vs données du web

Utilisateurs désireux de services de plus en plus sophistiqués

- adapter en temps réel le contenu et la navigation en fonction d'un profil
- petits objets portables communiquant
- assistants de communication
- →Web sémantique

Plan

Web sémantique

Modèle de données graphe - RDF

Langage de définition d'ontologies légères - RDFS

Langage de requêtage - SPARQL

Langage d'annotations HTML - RDFa - microdata

Langage de définitions d'ontologies lourdes - OWL

Web sémantique

Déf: Le Web sémantique désigne un ensemble de technologies visant à rendre le contenu des ressources du Web accessible et utilisable par les programmes et agents logiciels, grâce à un système de métadonnées formelles, utilisant notamment la famille de langages développés par le W3C

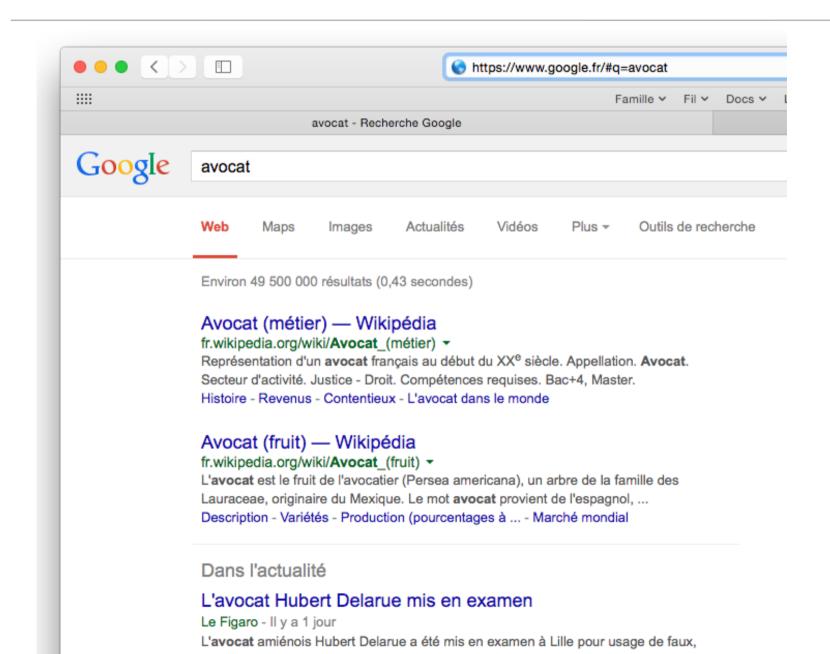
Web sémantique

Extraction d'information actuellement

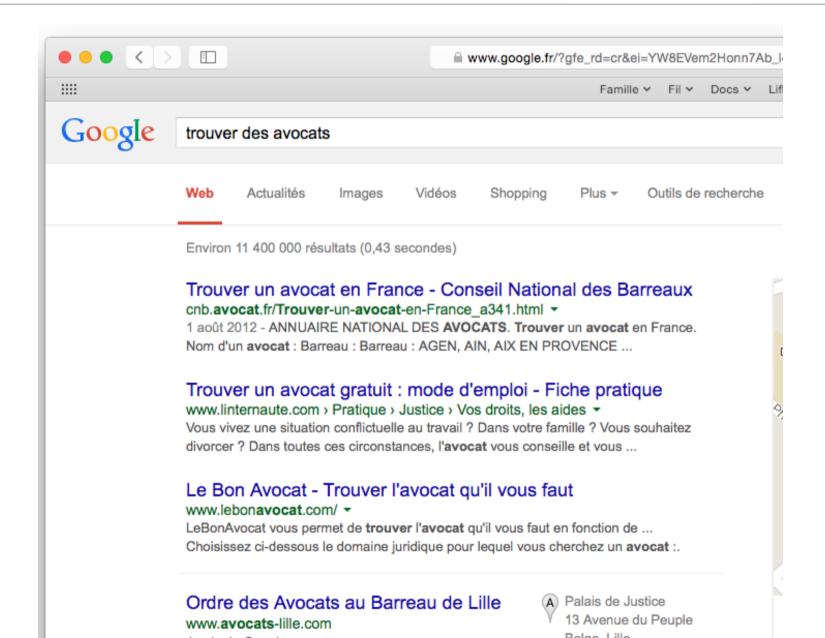
Recherche syntaxique par mots clés (wrappers - indexation)

Utilisateur humain interprète les résultats = trouve une sémantique puis éventuellement reformule sa requête.

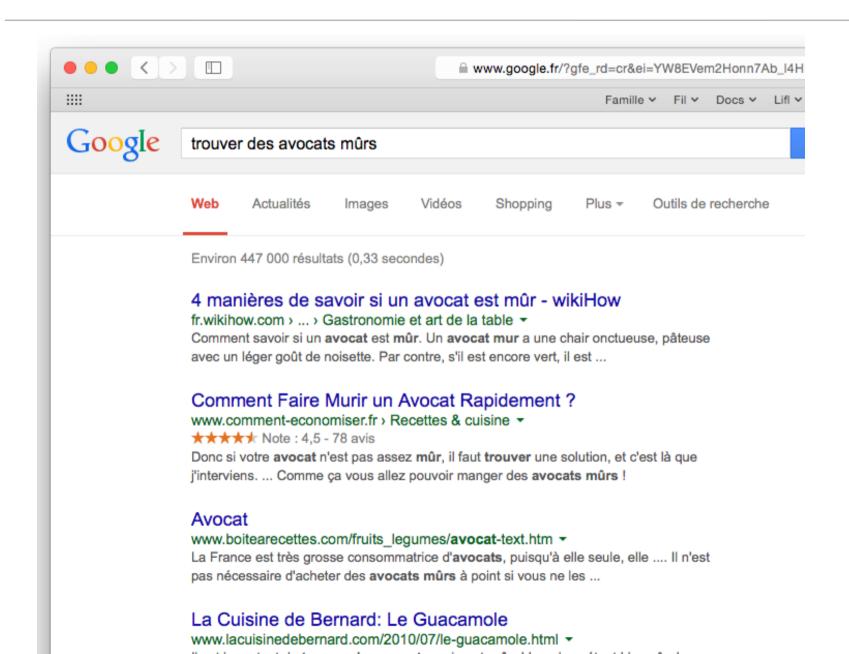
Extraction d'information



Extraction d'information



Extraction d'information



Web sémantique

Recherche de service sur le WEB actuellement

Décomposition de la demande en recherche de services et appels des différents services => même problème

Exemple : 1 week-end à Londres le week-end de Pâques

- géolocaliser le point de départ - trouver les moyens de transport - trouver des moyens d'hébergement - comparer les offres...

Que faudrait-il?

Il faudrait que les programmes (les services) puissent interpréter les données : ce document correspond à un hôtel, un hôtel est un mode d'hébergement, dans un hôtel on peut réserver une ou des chambres.

Un prérequis est de représenter les connaissances liées aux données pour faire des inférences : cette page représente un hôtel, un hôtel est un mode d'hébergement donc cette page représente un mode d'hébergement.

Nécessité d'ajouter des informations sémantiques, traitables par des machines. Lier des ressources du web par des propriétés.

Ambiguïté

retrouver le nom de la fille du journaliste qui a eu un accident.

le policier regardait l'espion avec des jumelles.

Chalenges

Liens avec des problématiques existantes : représentation des connaissances, compréhension du langage naturel, déduction automatique ...

Domaines : Sciences cognitives, intelligence artificielle, linguistique, logique

Spécificité: ressources du Web. Structuration de données existantes.

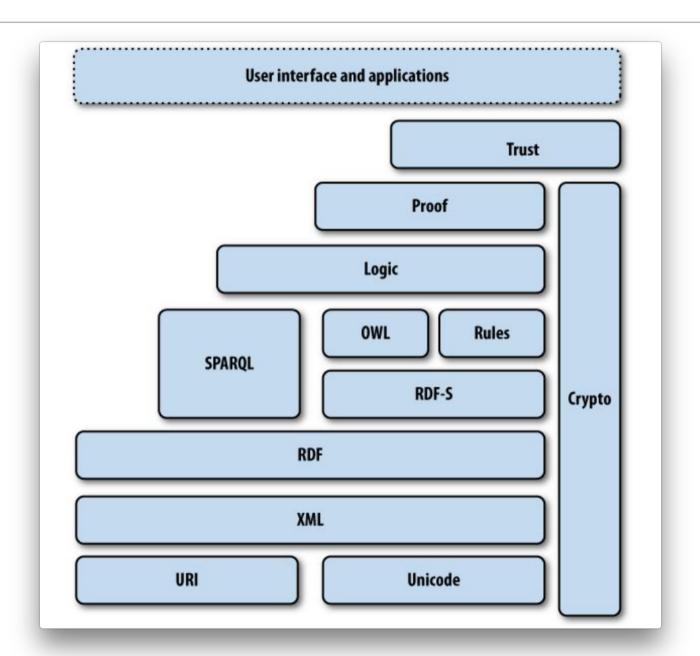
Chalenges: l'immensité, l'imprécision, l'incertitude, l'incohérence, et la tromperie

1994 idées émises par Tim Berners Lee,

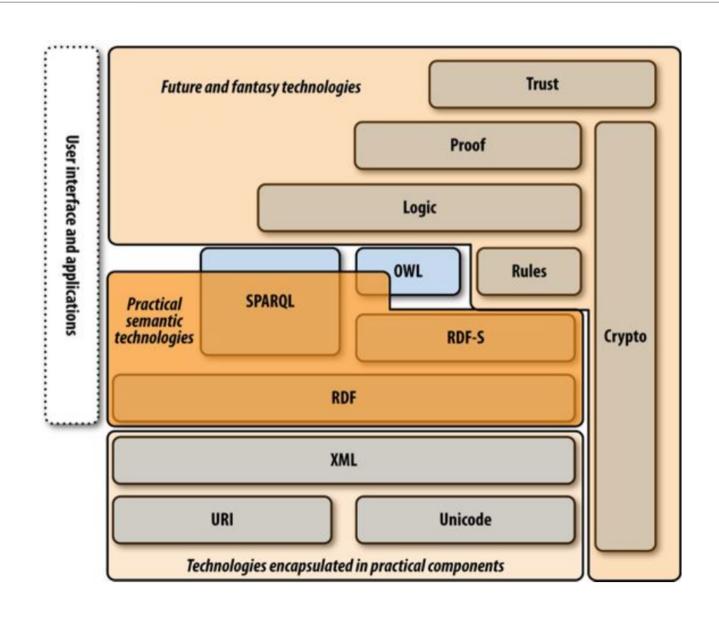
1998 formalisation des idées au w3c,

1998- langage de description rdf99, langage de schéma rdfs04, et de raisonnement owl, langage de requête sparql, ...

La pile du web sémantique



La vraie pile du web sémantique



Quelques exemples d'applications

Creative Commons : organisme qui a pour but de faciliter la diffusion et le partage des oeuvres numériques.

- définition de différentes licences qui définissent les conditions d'utilisation d'une oeuvre. Techniquement : annotation sémantique, par exemple avec RDFa.
- Les licences CC sont manipulables dans certaines applications comme Drupal ou Flickr : l'application se charge de l'annotation sémantique.

GoodRelations: vocabulaire sémantique pour le commerce électronique.

• permet d'échanger des informations sémantiques entre entreprises (fournisseurs, vendeurs, ...), de fournir des informations sémantiques aux moteurs de recherche partenaires du projet (Google, Yahoo ...).

Moteurs de recherche : initiative schema.org de Microsoft, Yahoo!, Google et Yandex.

LinkingOpenData: mise à disposition et utilisation de sources de données sur le Web.

Assistant personnel (comme Siri).

Plan

Web sémantique

Modèle de données graphe - RDF

Langage de représentation - RDFS

Langage de requêtage - SPARQL

Objectif

Lier des ressources du web par des propriétés.

Ressources?

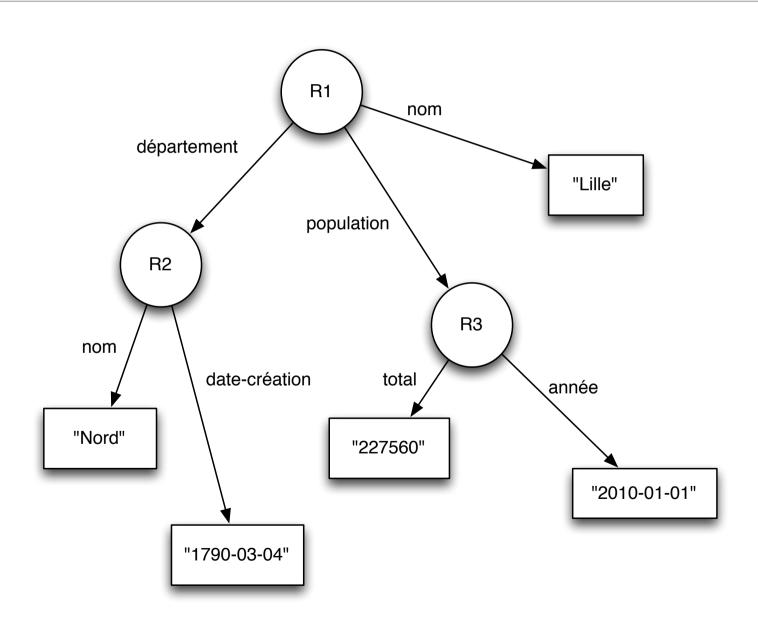
Tout objet d'intérêt.

- •ressource information : page web, url
 http://fr.wikipedia.org/wiki/Lille
- •ressource non information : pas d'url la ville de Lille (en tant qu'entité)

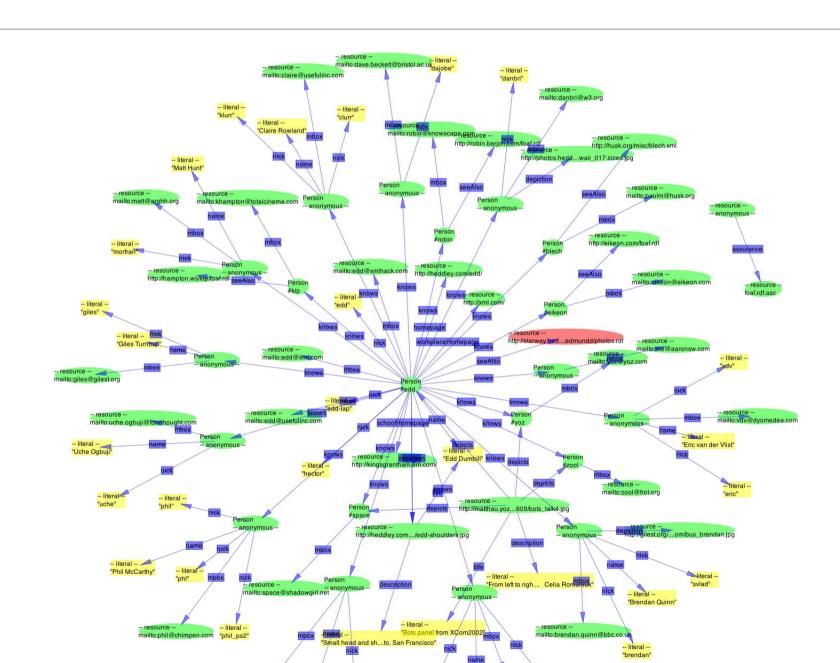
Lier les ressources : triplet

```
identifiant de ressource
 (R1 , nom , "Lille")
 (R1 , département , R2)
                                              littéral
 (R2 , nom , "Nord")
 (R2 , date-création , "1790-03-04")
 (R1 , population , R3)
 (R3 , total , "227560")
                                   nom de propriété ou prédicat
 (R3 , année , "2010-01-01")
           propriété
                          objet
sujet
```

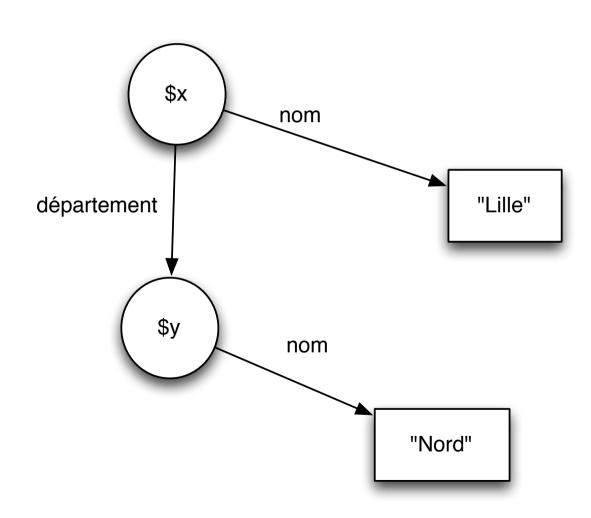
Modèle de base : graphe



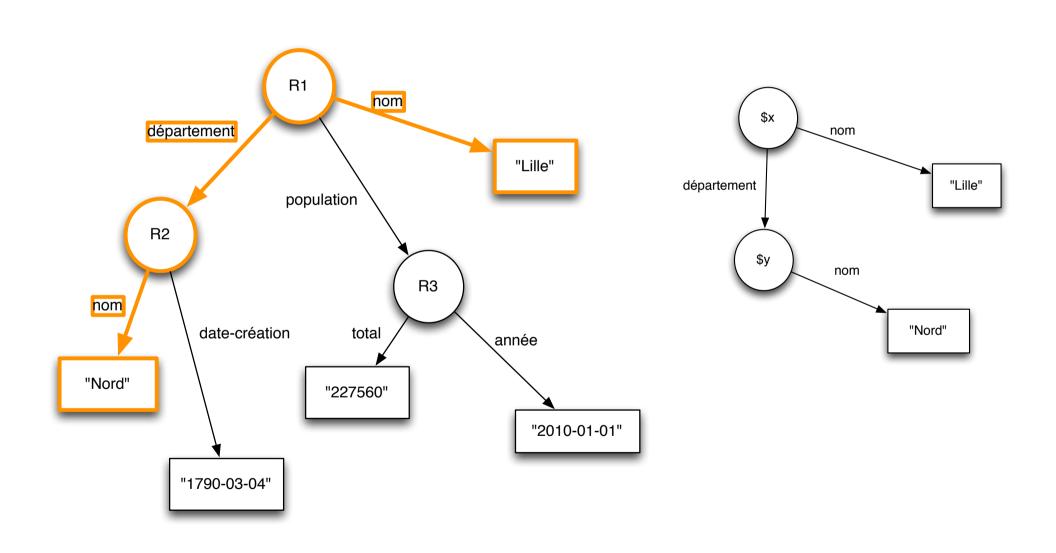
Modèle de base : graphe



Interroger: motifs de graphes



Interroger: motifs de graphes



donc un modèle simple

5.comment interroger en pratique?

```
(R1 , nom , "Lille")
modèle simple soit, mais...
                                    (R2 , date-création , "1790-03-04")
1.comment définir des identifiants de ressource à l'échelle du web et sans conflit de nom?
2.comment interpréter un littéral : quel est son type, son unité, ... ?
3.comment savoir quels prédicats utiliser : quels sont les noms de prédicats existants ?
4.comment publier les triplets sur le web?
```

donc un modèle simple : RDF

1.comment définir des identifiants de ressource à l'échelle du web et sans conflit de nom ? utilisation d'URI et d'espaces de noms

```
2.comment interpréter un littéral : quel est son type, son unité, ... ? information de typage (xs:integer, fil:m1, ...)
```

3.comment savoir quels prédicats utiliser : quels sont les noms de prédicats existants ? définis dans des vocabulaires appelés ontologies - RDFS

4.comment publier les triplets sur le web ?
différents formats de sérialisation (N Triples, xml/RDF, N3, ...)

5.comment interroger en pratique ?
langage de requêtes SPARQL

RDF

- RDF = Resource Description Framework
- Informations destinées aux applications (pas pour les humains!) d'extraction d'information et services web
- Quatre niveaux de modélisation
 - √ Graphe étiqueté (les triplets)
 - ✓ Ressources, prédicats, littéraux et déclarations
 - ✓ Types Complexe : containers et collections
 - ✓ Schémas RDFS : classes, types de propriétés
- De plus en plus de complexité et d'expressivité...RDF 1.0 en 2004, RDF 1.1 depuis février 2014.

Déclaration RDF

Une déclaration RDF est un triplet constitué d'un sujet, d'un prédicat et d'un objet :

Un sujet (obligatoirement une ressource) : C'est un objet du domaine nommé par un identifiant (URI ou ressource anonyme)

Un prédicat : C'est une relation binaire sur le domaine entre un sujet et un objet nommée par un identifiant qui est une URI.

Un objet : C'est la valeur du prédicat pour le sujet. Il s'agit soit d'une ressource (identifiée par une URI ou anonyme), soit un littéral (chaîne de caractères ou nombre ou ...)

noms de ressources : URI

URI = Uniform Resource Identifier

http://labd/2015/V_Lille

Souvent, en pratique URI-Reference

http://labd/2015#V_Lille

Intérêt : pour certains formats de sérialisation associer un préfixe à la base de l'URI pour simplifier

labd="http://labd/2015#"

labd:V_Lille

Les URI servent de noms pour les ressources mais aussi pour les prédicats

Littéraux

Un littéral consiste en un, deux ou trois éléments :

- 1. une forme lexicale : une chaîne de caractères Unicode.
- 2.une URI pour le type de données qui précise comment interpréter la chaîne de caractères.
- 3.un tag éventuel d'information de langue

Si on ne donne pas d'URI de typage, alors le type par défaut est xs:string, sauf s'il y a un tag de langage, le type est alors rdf:langString.

```
"1990-07-04"^^xsd:date
```

"La Joconde"@fr

Exemple revisité

```
(http://labd/2015#V Lille , http://labd/2015#nom , "Lille"@fr)
(http://labd/2015#V Lille, http://labd/2015#département , http://labd/2015#D Nord)
(http://labd/2015#D Nord , http://labd/2015#nom , "Nord")
(http://labd/2015#D Nord , http://labd/2015#date-création , "1790-03-04"^^xs:date)
(http://labd/2015#V Lille , http://labd/2015#population , R3)
(R3 , http://labd/2015#total , "227560"^^xs:integer)
(R3 , http://labd/2015#année , "2010-01-01"^^xs:date
```

Nœud anonyme (on dit aussi nœud blanc) ces noeuds anonymes peuvent être vus comme des variables

Les vocabulaires RDF

- On verra comment définir son propre vocabulaire, i.e. définir des URI pour les ressources (sujets, prédicats et objets) dont on veut parler avec RDFS.
- Il existe beaucoup de vocabulaires déjà définis : il faut donc les utiliser !
- Si malgré tout on a défini un URI (I1) pour parler d'un concept, et qu'une autre personne a défini un autre URI (I2) pour ce même concept, on peut dire à l'aide d'un triplet que "I1 est le même concept que I2".

quelques exemples de vocabulaires existants:

- FOAF pour des relations sociales,
- dublin core pour des documents,
- schema.org pour des moteurs de recherche, ...
- dbpedia pour annoter wikipedia



...although of course change the URL to point to your own FOAF document. See also: more on FOAF autodiscovery and services that make use of it.

FOAF cross-reference: Listing FOAF Classes and Properties

FOAF introduces the following classes and properties. A machine-friendly version is also available in RDF/XML.

Classes: I Agent I Document I Group I Image I LabelProperty I OnlineAccount OnlineChatAccount I OnlineEcommerceAccount I OnlineGamingAccount I Organization Person I PersonalProfileDocument I Project I Properties: I account I accountName I accountServiceHomepage I age I aimChatID

based_near | birthday | currentProject | depiction | depicts | dnaChecksum | familyName | family_name | firstName | focus | fundedBy | geekcode | gender | givenName | givenname | holdsAccount I homepage I icqChatID I img I interest I isPrimaryTopicOf I jabberID I knows lastName I logo I made I maker I mbox I mbox sha1sum I member I membershipClass I msnChatID | myersBriggs | name | nick | openid | page | pastProject | phone | plan primaryTopic | publications | schoolHomepage | sha1 | skypeID | status | surname | theme | thumbnail I tipiar I title I topic I topic interest I weblog I workInfoHomepage workplaceHomepage I vahooChatID I

Classes and Properties (full detail)

Classes

Class: foaf:Agent

Agent - An agent (eg. person, group, software or physical artifact).



3c. Missing/implicit information: use the meta tag with content

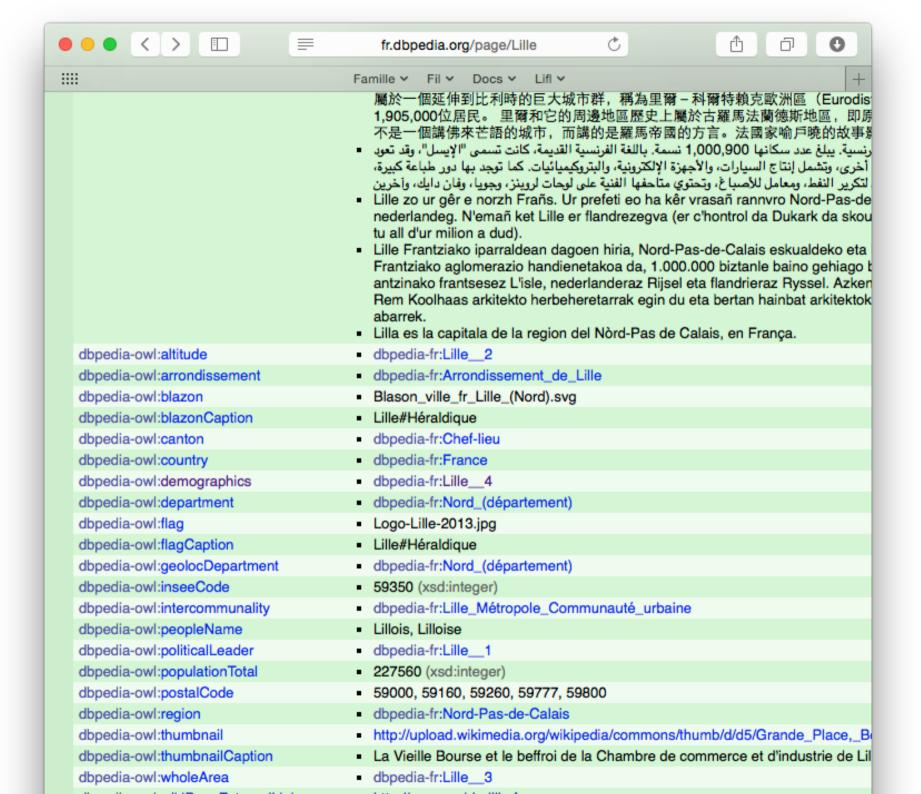
Sometimes, a web page has information that would be valuable to mark up, but the information can't be marked up because of the way it appears on the page. The information may be conveyed in an image (for example, an image used to represent a rating of 4 out of 5) or a Flash object (for example, the duration of a video clip), or it may be implied but not stated explicitly on the page (for example, the currency of a price).

In these cases, use the meta tag along with the content attribute to specify the information. Consider this example—the image shows users a 4 out of 5 star rating:

```
<div itemscope itemtype="http://schema.org/Offer">
    <span itemprop="name">Blend-O-Matic</span>
    <span itemprop="price">$19.95</span>
    <img src="four-stars.jpg" />
    Based on 25 user ratings
</div>
```

Here is the example again with the rating information marked up.

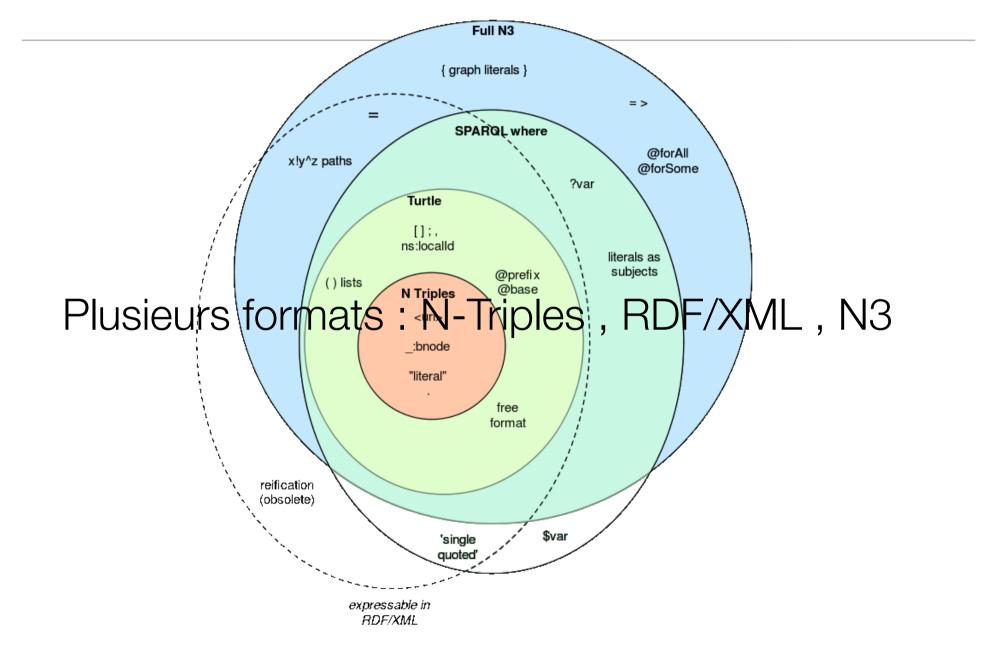
This technique should be used sparingly. Only use meta with content for information that cannot otherwise be marked up.



Exemple re-revisité

```
(http://labd/2015#V Lille , http://fr.dbpedia.org/property/nom , "Lille"@fr)
(http://labd/2015#V Lille, http://labd/2015#département , http://labd/2015#D Nord)
(http://labd/2015#D Nord , http://fr.dbpedia.org/property/nom , "Nord")
(http://labd/2015#D Nord , http://labd/2015#date-création , "1790-03-04"^^xs:date)
(http://labd/2015#V Lille , http://dbpedia.org/ontology/demographics , R3)
(R3 , http://dbpedia.org/ontology/populationTotal , "227560"^^xs:integer)
(R3 , http://dbpedia.org/ontology/year , "2010-01-01"^^xs:date)
```

Sérialisation



https://www.w3.org/DesignIssues/diagrams/n3/venn

N-Triple

```
La sérialisation la plus basique : chaque triplet est écrit sous la forme < URI du sujet> < URI du prédicat> < URI de l'objet> . Ou <math>< URI du sujet> < URI du prédicat> littéral .
```

voir http://www.w3.org/TR/n-triples/

N-Triple

```
<http://labd/2015#V Lille> <http://fr.dbpedia.org/property/nom> "Lille"@fr .
<http://labd/2015#V Lille>
    <http://labd/2015#département> <http://labd/2015#D Nord> .
<http://labd/2015#D Nord> <http://fr.dbpedia.org/property/nom> "Nord" .
<http://labd/2015#D Nord>
    <http://labd/2015#date-création>
    "1790-03-04"^^<http://www.w3.org/2001/XMLSchema#date> .
<http://labd/2015#V Lille> <http://dbpedia.org/ontology/demographics> :R3 .
:R3
    <http://dbpedia.org/ontology/populationTotal>
    "227560"^^<http://www.w3.org/2001/XMLSchema#integer> .
:R3
    <http://dbpedia.org/ontology/year>
    "2010-01-01"^^<http://www.w3.org/2001/XMLSchema#date> .
```

Turtle

Terse RDF Triple Language

- lisibilité : à destination des humains (et des machines aussi)
- définition de préfixes pour représenter les bases d'URI
- factorisation des triplets par sujet
- possibilités de définir des nœuds blancs vraiment anonymes

voir http://www.w3.org/TR/turtle/

Turtle

```
@base <http://labd/2015> .
@prefix dbpr: <http://fr.dbpedia.org/property/> .
@prefix dbon: <http://dbpedia.org/ontology/> .
@prefix xsd: <http://www.w3.org/2001/XMLSchema#> .
@prefix labd: <http://labd/2015#> .
<#V Lille>
    dbpr:nom "Lille"@fr;
    labd:département <#D Nord>;
    dbon:demographics :R3 .
<#D Nord>
    dbpr:nom "Nord" ;
    labd:date-création "1790-03-04"^^xsd:date .
_:R3
    dbon:populationTotal "227560"^^xsd:integer;
    dbon:year "2010-01-01"^^xsd:date .
```

syntaxe XML pour représenter un graphe RDF.

- élément Description pour décrire une ressource
- attribut about pour le sujet
- sous-élément pour le prédicat
- contenu du sous-élément pour l'objet (qui peut être parfois simplifié en attribut)
- on peut regrouper dans un même élément **Description** tous les prédicats dont cette ressource est sujet.

voir http://www.w3.org/TR/rdf-syntax-grammar/

```
<?xml version='1.0' encoding='utf-8' ?>
<rdf:RDF
  xmlns:rdf="http://www.w3.org/1999/02/22-rdf-syntax-ns#"
  xmlns:dbpr="http://fr.dbpedia.org/property/"
  xmlns:dbon="http://dbpedia.org/ontology/"
  xmlns:labd="http://labd/2015#">
    <rdf:Description rdf:about="http://labd/2015#V Lille">
        <dbpr:nom>Lille</dbpr:nom>
        <labd:département rdf:resource="http://labd/2015#D Nord"/>
        <dbon:demographics rdf:nodeID="R3"/>
   </rdf:Description>
    <rdf:Description rdf:about="http://labd/2015#D Nord">
        <dbpr:nom>Nord</dbpr:nom>
        <labd:date-création rdf:datatype="http://www.w3.org/2001/XMLSchema#date">
            1790-03-04
        </labd:date-création>
    </rdf:Description>
    <rdf:Description rdf:nodeID="R3">
        <dbon:populationTotal rdf:datatype="http://www.w3.org/2001/XMLSchema#integer">
            227560
       </dbon:populationTotal>
        <dbon:year rdf:datatype="http://www.w3.org/2001/XMLSchema#date">
            2010-01-01
        </dbon:vear>
    </rdf:Description>
</rdf:RDF>
```

Simplification

Quand un élément-propriété contient un littéral chaîne, on peut exprimer cette propriété comme attribut

devient

Ressources imbriquées

Quelques outils

• pour valider un document XML/RDF, visualiser les triplets et le graphes correspondants :

http://www.w3.org/RDF/Validator/

pour convertir et valider différents formats

http://rdf.greggkellogg.net/distiller